

Physical AI Assignment

2021741050 정태인

1. Dataset Extension

기존 시스템은 'grasp' 하나와 3개의 단순한 명령어 템플릿에만 의존하는 단조로운 환경이었습니다. 이를 극복하기 위해 Raccoon_colored_cylinder.xml을 활용하여 구체, 큐브 등을 포함한 6개의 다채로운 물체를 렌더링했습니다. 또한 데이터셋 수집 코드(collect_dataset) 내부에 push와 lift태스크에 대한 명령어 템플릿을 직접 추가하여 지시문의 다양성을 확보했습니다. 핵심 메인 루프가 목표 에피소드(총 400개)를 채울 때까지 물체의 초기 위치, 색상, 수행 작업을 무작위로 섞어 균형(Balancing)을 맞추도록 개선하여, 300개의 확장된 에피소드를 파인튜닝에 활용했습니다.

2. Code Improvement

① **동작 실행 속도 및 정밀도 최적화:** AI 모델의 보수적인 Z축 액션으로 인한 병목 현상을 해결하고자 액션 스케일링 파라미터(--delta_scale 1.5)를 추가하고, 대기 시간(settle_seconds)을 0.4초로 단축하여 상대적으로 빠른 연속 제어를 구현했습니다.

② **작업 성공 감지 및 자동 종료:** 무한 루프 문제를 해결하기 위해 MuJoCo의 env.data.qpos를 실시간 추적하여, 목표물이 1.5cm 이상 이동(Push)하거나 바닥에서 3cm 이상 상승(Lift)하면 즉시 [TASK SUCCESS]를 선언하고 시스템을 종료하는 성공 감지 로직을 추가했습니다.

3. Key Question: What makes the system faster, clearer, or more reliable?

- **Faster:** 카메라 대기 시간 단축과 Action 토큰 스케일 캘리브레이션으로 매니플레이션 소요 시간을 단축했으며, Auto-Termination 도입으로 잉여 연산 시간이 완전히 제거되었습니다.
- **Clearer:** 좌표 비교 로그와 성공/실패 판정 메시지를 터미널에 실시간 출력하여 디버깅 가시성을 확보했습니다.
- **More Reliable:** 시뮬레이터 단에서 물리 지표(거리, 높이)로 성공을 검증함으로써 전체 파이프라인의 객관적 신뢰성을 높였습니다.

4. 한계점 분석: VLA 모델의 일반화(Generalization) 및 행동 복제(BC)의 취약성

총 400개의 에피소드를 균등하게 섞어 파인튜닝을 진행했음에도 불구하고, 실제 테스트 과

정에서 모방 학습 기반 모델의 뚜렷한 한계점들이 관찰되었습니다.

- **공간적 일반화 실패:** 물체가 로봇의 작업 반경에서 너무 멀거나 가까운 극단적인 위치에 스폰될 경우, 모델이 물체가 없는 허공으로 팔을 뻗는 현상이 발생했습니다. 이는 모델이 시각적으로 물체를 인식했더라도, 학습 분포를 벗어난 좌표에 대한 올바른 Action 토큰을 매핑하지 못함을 의미합니다.
- **상태 이상에 따른 프리징 및 충돌 정지:** 목표 물체가 아닌 엉뚱한 물체와 부딪히거나 허공에 도달했을 때, 로봇이 스스로 에러 누적을 인지한 듯 특정 좌표에 멈춰서 움직이지 않는 현상이 빈번했습니다.
- **연속된 액션 토큰의 불안정성:** Push의 경우 그리퍼를 닫은 상태를 유지해야 함에도 불구하고, 이동하는 내내 그리퍼를 벌렸다 줄였다(0과 1 사이의 중간값 출력)를 반복하는 불안정한 모습이 관찰되었습니다.
- **태스크 복잡도에 따른 성능 편차:** 데이터셋의 분포를 동일하게 맞추었음에도 2D 평면 기반의 Push나 Grasp는 비교적 원활하게 수행된 반면, 추가적인 Z축 궤적이 요구되는 Lift태스크는 성공률이 현저히 떨어졌습니다.

5. 결론 및 향후 과제

본 프로젝트에서는 파인튜닝 과정에서 태스크별 템플릿을 확장하여 학습을 진행했습니다. 여기서 "명령어 템플릿을 수십, 수백 가지로 다양화했다면 로봇이 더 정확하게 작동했을까?"라는 의문이 제기될 수 있습니다. 그러나 언어의 다양화는 로봇이 낯선 명령을 알아듣는 의미적 일반화 능력을 향상시킬 뿐, 본 테스트에서 관찰된 허공 찌르거나 충돌 프리징 같은 물리적 한계를 직접적으로 해결해주지는 못합니다. 모델이 물리적 오류를 스스로 극복하려면 기계적인 물체 재배치를 넘어서, 극단적인 좌표 스폰 상황과 충돌 후 궤적을 복구하는 과정 등 물리적 상황 공간의 다양성이 훈련 데이터에 포함되어야 합니다.

그럼에도 불구하고 진정한 의미의 인간-로봇 상호작용을 달성하기 위해서는 템플릿 구조를 탈피해야 합니다. 향후에는 더욱 방대한 텍스트 증강을 통해, 사용자가 비정형화된 일상 언어를 입력하더라도 VLA 내부에 탑재된 거대 언어 모델이 스스로 의도를 파악하고 행동 궤적과 조합해 낼 수 있는 시스템으로 발전해 나가야 할 것입니다.